

Practica_PLN_Grupo08

2025-12-04

Práctica 8

CUIDADO AL EJECUTAR (Limpia el Global Enviroment)

```
rm(list = ls())
```

Lectura del archivo 10000 palabras

```
## Lectura del html y transformación a dataframe
```

```
# Leer el archivo
```

```
lineas <- readLines("10000_formas_ortograficas.txt",  
                    encoding = "UTF-8")
```

```
lineas[0:4]
```

```
## [1] "Forma\tFrecuencia\tFrec. norm." ",\t27823866\t56483.65"
```

```
## [3] "de\t26286396\t53362.52"          ".\t19226627\t39030.88"
```

```
# Buscar donde empieza la priemra linea
```

```
linea_inicio <- grep("^~0-9\t~n]+~t[0-9]+~t[0-9]+", lineas)[1]
```

```
# Extraer 10000 líneas a partir del inicio
```

```
datos <- lineas[linea_inicio:(linea_inicio + 9999)]
```

```
# Separar cada línea por tabulador (\t)
```

```
partes <- strsplit(datos, "\t")
```

```
partes[0:4]
```

```
## [[1]]
```

```
## [1] ", "      "27823866" "56483.65"
```

```
##
```

```
## [[2]]
```

```
## [1] "de"      "26286396" "53362.52"
```

```
##
```

```
## [[3]]
```

```
## [1] ". "      "19226627" "39030.88"
```

```
##
```

```
## [[4]]
```

```
## [1] "la"      "15799962" "32074.6"
```

```

# Extraer las columnas
formas <- sapply(partes, function(x) x[1])
frecuencias <- as.numeric(sapply(partes, function(x) x[2]))
frec_norm <- as.numeric(sapply(partes, function(x) x[3]))

# Crear el dataframe
tabla <- data.frame(Forma = formas,
                    Frecuencia = frecuencias,
                    Frec.norm = frec_norm,
                    stringsAsFactors = FALSE)

head(tabla)

```

```

##      Forma Frecuencia Frec.norm
## 1      ,      27823866  56483.65
## 2     de      26286396  53362.52
## 3      .      19226627  39030.88
## 4     la      15799962  32074.60
## 5     que      13350795  27102.69
## 6      y      11562228  23471.82

```

```

tail(tabla)

```

```

##              Forma Frecuencia Frec.norm
## 9995      militancia      3422      6.94
## 9996      perciben      3421      6.94
## 9997      católico      3421      6.94
## 9998      convertía      3421      6.94
## 9999  especialización      3421      6.94
## 10000      golpeó      3421      6.94

```

Apartado 1.1

Apartado 1.2

```

## Apartado 1.2

# Pasar todo a minúsculas
tabla$min_forma <- tolower(tabla$Forma)

# Contar cuántas formas básicas tienen variantes
conteo <- table(tolower(tabla$Forma))
duplicados <- conteo[conteo > 1]

cat("Formas básicas con duplicados no exactos:", length(duplicados), "\n")

```

```

## Formas básicas con duplicados no exactos: 760

```

```

# Mostrar primeros 5 ejemplos
cat("\nPrimeros 5 ejemplos:\n")

```

```
##  
## Primeros 5 ejemplos:  
  
for (i in 1:5) {  
  forma <- names(duplicados)[i]  
  variantes <- unique(tabla$Forma[tolower(tabla$Forma) == forma])  
  cat(i, " '", forma, "' con las variantes: ", paste(variantes, collapse = ", "), "\n", sep = "  
}  
  
## 1 'a' con las variantes: a, A  
## 2 'abierto' con las variantes: abierto, Abierto  
## 3 'acá' con las variantes: acá, Acá  
## 4 'academia' con las variantes: Academia, academia  
## 5 'acaso' con las variantes: acaso, Acaso
```

Apartado 1.3

```
# Función para detectar si la palabra contiene caracter no español
tiene_no_espanoles <- function(texto) {
  grepl("[^A-Za-zÑñÁáÉéÍíÓóÜü .,:;!¿?--]", texto)
}

no_espanol <- tiene_no_espanoles(tabla$Forma)

# Número de palabras con caracteres no españoles (según nuestro criterio)
num_no_espanol <- sum(no_espanol)
cat("El nº de formas no españolas según nuestro criterio es: ", num_no_espanol)
```

```
## El nº de formas no españolas según nuestro criterio es: 224
```

```
#Ejemplos
head(tabla$Forma[no_espanol],20)
```

```
## [1] "\" \" \" \" \" (\" \">\" \"<\" \" \" \"1\" \"2\" \" \" \" \" \"3\" \"4\" \"-\" \"10\" \"5\"
## [16] \"6\" \"20\" \"15\" \"7\" \"12\"
```